Social Media Regulieren. Aber Wie?

Fachgespräch “Social Media goes Social”, Konrad-Adenauer-Stiftung, 04.11.2026

Papier zum Vortrag von Prof. Dr. Aurelia Tamò-Larrieux und Prof. Dr. Simon Mayer

Deutschland kann die Risiken von Social Media Plattformen wirksamer verringern als mit einer Altersgrenze, wenn es am Produkt ansetzt statt an Verboten für Nutzerinnen und Nutzern. Wir beschreiben einen Rahmen aus vier regulatorischen Hebeln, die zusammenwirken und weitergedacht werden können, sowie konkrete Vorschläge für nächste Schritte.

Die Altersgrenze allein wirkt kaum

Die Bundesregierung hat am 14. Oktober 2026 Eckpunkte beschlossen: Kinder unter 13 Jahren sollen soziale Netzwerke grundsätzlich nicht nutzen, bis ein EU-Mindestalter gilt. Für 13- bis 18-Jährige sind abgestufte Beschränkungen vorgesehen, die noch nicht konkretisiert sind.

Erfahrungen aus anderen Ländern sprechen gegen eine Altersgrenze als Hauptinstrument. In Australien nutzten drei Monate nach Inkrafttreten des Verbots für unter 16-Jährige über 85 % der Betroffenen die gesperrten Plattformen weiter (Barnes et al. 2026). Zudem, und prinzipiell, ist das Alter nur ein grober Stellvertreter für Schaden: Die Risiken entstehen durch das Design und das Ranking der Feeds, und sie treffen Erwachsene ebenso, etwa vor Wahlen. Zuletzt schafft eine Altersgrenze auch die positiven Aspekte von sozialen Netzwerken für die Betroffenen ab.

Während wir nun im 2026 “immer noch” über soziale Netzwerke diskutieren, sollten wir nicht aus den Augen verlieren, dass **KI-Chatbots vermehrt “künstlich-soziale” Interaktionen mitprägen** werden. Die Befunde im Kontext sozialer Netzwerke helfen uns, bereits jetzt einen besseren Einblick zu erhalten, welche regulatorischen Hebel in Zukunft zielführend sein können.

Wie regulieren? Vier regulatorische Hebel.

Wir strukturieren Regulierungsmöglichkeiten von Social Media Plattformen und ihren zugrundeliegenden Algorithmen- und Benutzerschnittstellendesigns in vier Hebel. Diese unterscheiden sich darin, wie die Regulierung den Mechanismus kennen muss, den sie regelt:

- **Hebel I** verpflichtet Plattformen allgemein, systemische Risiken zu mindern, und schafft Transparenz
- **Hebel II** beschränkt den Zugang zu Plattformen und ihren Feeds
- **Hebel III** regelt konkrete Funktionen der Benutzerschnittstelle und des Empfehlungsalgorithmus
- **Hebel IV** ändert die wirtschaftlichen Anreize der Plattformen

Hebel I: Systemrisiken bewerten und transparent kommunizieren

Hebel I ist bereits gut etabliert: sehr große Online-Plattformen bewerten jährlich selbst, welche systemischen Risiken von ihren Diensten ausgehen, etwa für den öffentlichen Diskurs, für Wahlen oder für die psychische Gesundheit ihrer Nutzerinnen und Nutzer, und ergreifen Gegenmaßnahmen (Art. 34 und 35 Digital Services Act; DSA). Unabhängige Prüferinnen überprüfen die Einhaltung dieser Pflichten jährlich (Art. 37 DSA), und geprüfte Forscherinnen erhalten Zugang zu Plattformdaten (Art. 40 DSA). Kleinere Plattformen sind nicht erfasst. Die Regulierung muss die Mechanismen dabei nicht im Einzelnen kennen; die Plattformen sollen sie selbst finden und entschärfen.

Der Hebel ist flexibel, hält mit neuen Funktionen Schritt und schafft Evidenz. Wenn Plattformen Daten teilen, wird kausale Forschung möglich: In Zusammenarbeit mit Meta wurden Feeds während eines Wahlkampfs erstmals experimentell verändert (Guess et al., 2023). Die standardisierten Begründungen für Moderationsentscheidungen in der Transparenzdatenbank des DSA machen Moderation im grossen Massstab vergleichbar, auch wenn die Angaben lückenhaft sind (Kaushal et al., 2024). Mit simulierten Konten lässt sich zudem im Prinzip unabhängig messen, was Feeds ausspielen (Bekavac et al., 2026).

Die Schwäche des Hebels ist die Prüfbarkeit, denn die Plattformen benoten sich weitgehend selbst. Ihre Risikoberichte bleiben oft bei allgemeinen Erklärungen oder sind gar unvollständig, belegen Aussagen zu Risiken und Gegenmaßnahmen selten mit Evidenz (ECNL, 2026) und legen die Optimierungsziele der Empfehlungssysteme nicht offen (Boratto et al., 2026), und der Datenzugang für die Forschung funktioniert bisher unzureichend und liefert nachweislich unvollständige Datensätze (Bekavac et al., 2026). Bei Risiken für Kinder sehen die Plattformen die Ursache meist im Verhalten der Nutzerinnen statt im eigenen Design, messen die Wirksamkeit ihrer Maßnahmen vor allem an Löschquoten und Reaktionszeiten und schwärzen gerade die aufschlussreichen Zahlen: Snap etwa veröffentlicht weder die durchschnittliche Nutzungszeit Minderjähriger noch, wie oft EU-Minderjährige regelwidrige Inhalte sehen. Selbst Forschung, die in Kooperation mit Meta durchgeführt wurde, blieb nach dem Urteil ihres unabhängigen Berichterstatters eine «Unabhängigkeit mit Erlaubnis» (Wagner 2023).

Hebel I bezieht sich stark auf bereits geltendes Recht. **Dieses sollte konsequenter durchgesetzt werden, um seine Wirkung zu entfalten.** Dies beinhaltet die Bereitstellung vollständiger Risikoberichte, funktionierenden Datenzugang nach Art. 40 DSA, sowie die Erlaubnis der unabhängigen Prüfung von außen durch simulierte Konten.

Hebel II: Zugang zu Plattformen kontrollieren

Hebel II hat zum Ziel, bestimmte Gruppen zu bestimmten Zeiten von bestimmten Feeds fernzuhalten, **regelt jedoch nicht die schädlichen Mechanismen selbst** - beispielsweise über ein Mindestalter mit Alterskontrolle beim Konto oder über Zeitsperren, etwa nachts. Australien sperrt seit Dezember 2025 Konten von unter 16-Jährigen, die Bundesregierung plant eine Grenze bei 13 Jahren, und der Vorschlag der EU-Kommission für den KIDS Act sieht unter 13 Jahren keinen Zugang und bis 15 Jahre eingeschränkte, von den Eltern verwaltete Konten vor

(EU-Kommission, 2026c). Die Alterskontrolle beruht auf Ausweisen, auf einer Schätzung des Alters aus Selfies oder auf der Analyse der genutzten Inhalte. Datenschutzfreundlicher sind die EUDI-Wallet und Zero-Knowledge-Beweise, die nur bestätigen, dass jemand eine Altersgrenze erreicht, jedoch nicht weitere Inputdaten benötigen.

Zugangsbarrieren sind einfach und politisch/gesellschaftlich sichtbar. Die Evidenzbasis, wie effektiv solche Zugangsbarrieren sind, ist jedoch schwierig abzuschätzen, auch deswegen, weil sie schwer durchsetzbar ist. Während eine Studie, die die gestaffelte Einführung von Facebook an US-Colleges analysierte, aufzeigte, dass sich die psychische Gesundheit der Studierenden verschlechterte seit Zugang zu Facebook (Braghieri et al., 2022), zeigen die Daten aus Australien, dass Zugangsbarrieren den sozialen Medien Konsum nur wenig beeinflussen (von 78 auf 69 %; siehe Barnes et al., 2026). Die Sperre wird breit umgangen und Alterskontrollen schaffen neue Risiken für Datenschutz und IT-Sicherheit. Bei Discord wurden 2025 über einen Dienstleister möglicherweise rund 70 000 Ausweisfotos offengelegt, die Nutzerinnen und Nutzer für Einsprüche gegen eine Alterseinstufung eingereicht hatten (Discord 2025). Fraglich ist weiter, ob das Alter den Schaden gut abbildet: In großen Datensätzen erklärt die Nutzung digitaler Technologie höchstens 0,4 % der Unterschiede im Wohlbefinden Jugendlicher (Orben & Przybylski 2019). Ein fundamentales Problem ist, dass altersbasierte Zugangsbarrieren die gesellschaftlichen Probleme, welche Social Media Plattformen mit sich bringen, nicht an der Wurzel zu beheben versucht, sondern zu Problemen von bestimmten Nutzergruppen macht (z.B. eben Kindern), welchen dadurch auch die positiven Effekte von Social Media vorenthalten würden (vorausgesetzt natürlich, dass die Zugangsbarriere funktionieren würde).

Hebel-II-Maßnahmen taugen unserer Einschätzung nach lediglich als Ergänzung eines Maßnahmenpakets, und auch hier nur, wenn sie datenschutzfreundlich umgesetzt werden. Wir raten generell davon ab, Zugangsbarrieren an das Lebensalter zu koppeln.

Hebel III: Gezielte Designeinschränkungen verlangen

Hebel III regelt bestimmte Plattformmechanismen gezielt. Diese Mechanismen betreffen das Interface (z.B. Endlos-Scroll, Autoplay, sichtbare Likes, Push-Nachrichten) sowie den Empfehlungsalgorithmus selbst (z.B. Ranking-Methode, Feed ohne Profiling, Bevorzugung von “Public Value” Inhalten). Der DSA verbietet Online-Plattformen adversariale Dark Patterns (Art. 25), verlangt Transparenz über die wichtigsten Parameter des Rankings (Art. 27) und von sehr grossen Plattformen einen Feed ohne Profiling (Art. 38). Der Vorschlag der EU-Kommission für den KIDS Act (EU-Kommission, 2026c) sowie der Vergleich zwischen Meta und 51 US-Generalstaatsanwaltschaften (Connecticut Attorney General, 2026) tragen hier noch weitere Designeinschränkungen bei, etwa Grenzen für Endlos-Scrolls, nächtliche Sperren und weniger Push-Benachrichtigungen für Minderjährige. Umsetzen lassen sich solche Regeln als feste Vorgaben, etwa über einen Scroll-Stopp nach einer bestimmten Zeit, oder über offene Schnittstellen, mit denen Nutzerinnen oder Dritte das Ranking selbst einstellen.

Diese Regeln zielen direkt auf den Schadensmechanismus, und ob eine Plattform eine solche Regel einhält, kann geprüft werden. Wissenschaftlich ist die Wirksamkeit von Eingriffen gut belegt: Die Bündelung von Benachrichtigungen (statt Push) verbessert Stimmung und

Kontrollgefühl (Fitz et al., 2019); Abschaltung von Autoplay und automatischen Empfehlungen erhöht das Gefühl der Selbstbestimmung (Lukoff et al., 2021); und ein chronologischer Feed anstelle eines profilbasierten Feeds senkt die Nutzungszeit deutlich (Guess et al., 2023). Das Ranking lässt sich sogar ohne Mitwirkung der Plattform verändern: Ein Re-Ranking per Browser-Erweiterung, das parteiische Feindseligkeit verringerte, verringerte affektive Polarisierung (Piccardi et al. 2025).

Diese Belege betreffen einzelne Eingriffe und nicht ihr Zusammenspiel, und nicht jeder Eingriff wirkt wie erwartet. Der chronologische Feed zeigte weniger für das Nutzerprofil passende Inhalte und änderte politische Einstellungen nicht (Guess et al., 2023). Das Abschalten des Algorithmus von X machte dessen Wirkung auf politische Einstellungen nicht rückgängig (Gauthier et al., 2026). Feste Vorgaben greifen zudem in die Wirtschaftsfreiheit ein, hinken neuen Funktionen hinterher und können Nutzerinnen und Nutzer motivieren, auf andere Plattformen zu wechseln.

Hebel-III-Massnahmen existieren bereits im geltenden europäischen Recht (siehe Art. 38 DSA und Urteile gegen Meta in Amsterdam u. a. Rechtbank Amsterdam, 2025; Gerechtshof Amsterdam, 2026) und werden auch im KIDS ACT stark hervorgehoben. Auch in anderen Ländern, wie den USA und China, sind solche Mechanismen bekannt (z. B. New York State, 2026; Connecticut Attorney General, 2026; Cyberspace Administration of China, 2024). Der KIDS Act übernimmt damit Mechanismen, die zuerst anderswo erprobt wurden; ein umgekehrter «Brussels Effect» (Inverarity et al., 2026).

Hebel IV: KPIs von Social Media Plattformen anpassen an gesellschaftliche Erwartungen

Feeds optimieren heute auf Engagement und Werbeumsatz. Hebel IV setzt an diesen bestehenden Key Performance Indicators (KPIs) an. In diesem Rahmen geht der Vorschlag am Weitesten, soziale Medien als öffentliche Infrastruktur zu behandeln: Neben die privaten Plattformen tritt eine öffentliche, die nach dem Vorbild des öffentlich-rechtlichen Rundfunks unabhängig beaufsichtigt wird und nicht auf Werbeumsatz optimieren muss (Mueller-Bloch & Ciriello, 2026). Umzusetzen ist der Hebel vor allem rechtlich; technisch verlangt er neue Messgrößen, etwa Wohlbefinden statt Verweildauer.

Der Hebel setzt an der Ursache an und wirkt auf allen Plattformen. Die Zielgrösse prägt, was Menschen sehen: Ein Ranking nach Engagement verstärkte feindselige Beiträge über die politische Gegenseite, ein Ranking nach den erklärten Präferenzen der Nutzerinnen und Nutzer dämpfte sie (Milli et al., 2025). Der Algorithmus von X verschob politische Einstellungen hin zu konservativeren Positionen (Gauthier et al., 2026).

Hebel IV greift stark in den Markt ein, und Schäden lassen sich einem einzelnen Feed schwer zuordnen. Die gemessenen Effekte sind klein: Das Re-Ranking von Piccardi et al. (2025) veränderte die Gefühle gegenüber der Gegenseite um rund 2 Punkte auf einer Skala von 100. Ein Ranking nach erklärten Präferenzen kann Echokammern verstärken (Milli et al., 2025), und die Öffnung hin zur Möglichkeit des Angebots eigener Feeds (i.e., Trennung von Feed und

Hosting) erzeugt Fragen zu Datenschutz, Kosten und Moderation (Keller 2021). Mueller-Bloch und Ciriello (2026) halten Haftung und Sorgfaltspflichten für private Plattformen grundsätzlich für unzureichend, weil Engagement zugleich Gewinn und Schaden antreibt; eine öffentliche Plattform braucht ihrerseits Schutz vor parteipolitischer Vereinnahmung, unter Umständen bis hin zu Verfassungsänderungen.

Hebel IV braucht neue Gesetze und wirkt erst mittelfristig. Aufgrund des starken Markteingriffs sind manche seiner Möglichkeiten bezüglich ihrer politischen Umsetzbarkeit fragwürdig und würden zu geopolitischen Spannungen beitragen. Andere, moderatere, Möglichkeiten sollten unserer Einschätzung nach geprüft werden.

Kombination der regulatorischen Hebel

Aus unserer Sicht ist die Wirksamkeit der Kombination der oben beschriebenen Regulierungshebel wesentlich. Hebel I sollte jetzt durchgesetzt werden, Hebel III sollte dort eingesetzt werden, wo Evidenz vorliegt; gleichzeitig sollte weitere Evidenz geschaffen werden, idealerweise mit signifikanten Populationsgrößen und im Deutschen Kontext. Hebel IV sollte als langfristiger Ansatz vorbereitet werden und Hebel II sollte nur ergänzend und datenschutzfreundlich eingesetzt werden. Ein “Recht auf Anpassung” (cf. Tamò-Larrieux et al., 2021) verbindet die Hebel, weil es Nutzerinnen und Nutzern die Wahl zwischen Varianten eines Dienstes lässt und zugleich messbar macht, welche Variante wie wirkt.

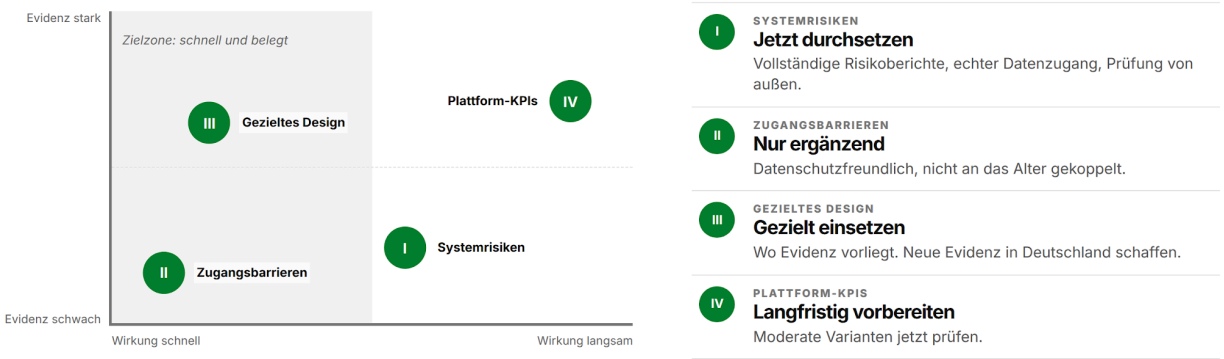


Abbildung 1: Die vier regulatorischen Hebel nach Umsetzungstempo und Evidenz, mit unseren Empfehlungen.

Was tun wir jetzt? Ein Vorschlag.

Die Politik will handeln. Regulatorische Hebel helfen, auf strukturierte Art und Weise konkrete Maßnahmen zu ergreifen, die in das bestehende Recht einfließen könnten.

Strukturierte Datensammlung und Feed-TÜV

Was Feeds anzeigen, wissen vor allem die Plattformen. Von 51 entschiedenen Anträgen auf Datenzugang nach Art. 40 DSA wurden 27 abgelehnt (DSA40 Data Access Collaboratory, 2026), und die Forschungsschnittstellen von TikTok und Instagram liefern nur 50 bis 75 % der tatsächlich ausgespielten Beiträge und 0% der problematischen Beiträge (Bekavac & Mayer, 2026). Ohne unabhängige Messung kann nicht belegt werden, dass eine Plattform ihre Pflichten erfüllt.

Eine kleine, **dauerhafte Stelle mit gesetzlichem Mandat und eigenem Budget misst mit simulierten Konten, was Feeds in Deutschland ausspielen,** etwa einer 14-Jährigen in Leipzig oder einem Erstwähler in Bayern; die Methode ist erprobt (z.B. Bekavac et al., 2026). Die Stelle veröffentlicht monatlich einen Feed-Bericht, in den sechs Wochen vor Bundestags- und Landtagswahlen wöchentlich, und übermittelt ihre Befunde der Bundesnetzagentur und der EU-Kommission als Belege für Verfahren nach Art. 34 und 35 DSA. Organisiert werden könnte die Stelle nach dem Vorbild der Bundesagentur für Sprunginnovationen, mit freier Personalauswahl.

Diese Stelle beobachtet, was öffentlich sichtbar ist, indem Datenzugang nach Art. 40 Abs. 12 DSA genützt werden, ohne neue Pflichten für Plattformen zu begründen. Nötig ist ein nationales Forschungsprivileg, das die simulierten Konten gegen Sperren nach den Nutzungsbedingungen absichert. Weil die Konten Daten Dritter sehen, sind Datensparsamkeit und die Aufsicht der Bundesdatenschutzbeauftragten nötig. Die Stelle legt weiters einen öffentlichen Prüfkatalog vor, welcher festlegt, wann ein Feed die Prüfung besteht; Plattformen, die diese Prüfung bestehen, erhalten eine Prüfplakette mit Ablaufdatum und eine Mängelabstufung richtet sich nach der bereits etablierten Methode der Hauptuntersuchung. Zwischen den Prüfungen dienen die monatlichen Messungen als Stichproben, ähnlich einer Verkehrskontrolle. Auf nationaler Ebene bleibt die Prüfung freiwillig, damit keine neuen Pflichten für Plattformen entstehen. Den Anreiz schafft die Werbewert-Abgabe, deren reduzierter Satz eine gültige Plakette voraussetzt (siehe unten). Dem Vorwurf einer Zensurbehörde begegnet die Stelle, indem sie nur misst, nichts löscht, und Methoden und Daten offenlegt.

Voreinstellungen, um Suchtverhalten zu minimieren: “*Not addictive by default*”

Oft beginnt die Nutzung mit einem Lockruf der App: einer Push-Nachricht, einem roten Zähler oder einer drohenden Streak-Strafe (ein “gamification”-Element). In 95 % von 240 populären Apps fanden Forschende mindestens ein Dark Pattern (Di Geronimo et al., 2020). Schon milde Dark Patterns verdoppelten in einem Experiment die Zustimmung zu einem fragwürdigen Angebot (Luguri & Strahilevitz, 2021), und eingeschaltete Benachrichtigungen erhöhten Unaufmerksamkeit und Hyperaktivität (Kushlev et al., 2016). Die EU-Kommission hat im Februar 2026 vorläufig festgestellt, dass TikToks Endlos-Scroll, Autoplay und Push-Benachrichtigungen gegen den DSA verstoßen (EU-Kommission, 2026a). In den USA hat Meta im August 2026 in einem Vergleich mit 51 Generalstaatsanwaltschaften unter anderem

nächtliche Sperren und Einschränkungen von Push-Benachrichtigungen für Minderjährige zugesagt (Connecticut Attorney General, 2026). Viele dieser Muster sind daher schon heute als unlauter oder unzulässig eingestuft, dies müsste aber durchgesetzt werden.

Es ist gut dokumentiert, welche Funktionalitäten Menschen auf die Plattform ziehen oder sie am Verlassen hindern. Diese Funktionalitäten sollten per Voreinstellung nicht aktiviert sein und nur durch Nutzerinnen oder Nutzer aktiv geändert werden können. Zum Beispiel könnten Lock-Benachrichtigungen wie «Du hast etwas verpasst» standardmäßig ausgeschaltet sein. Nachrichten von echten Personen bleiben erlaubt, und wer will, erhält eine gebündelte Zusammenfassung zu festen Zeiten (siehe Fitz et al., 2019). Auch sollten Streaks mit Verlustdrohung (z.B. "*Komm auf die Plattform, sonst…*"), künstliche adversariale Countdowns (z.B. "*Nur noch 9 Sekunden, damit du…*"), beschämende Ablehnungstexte (z.B. "*Nein danke, ich will lieber etwas verpassen.*") und wiederholtes Nachfragen nach einer getroffenen Entscheidung (z.B. "*Wolltest du wirklich nicht…*") per Voreinstellung abgeschaltet sein. Auch ein generelles Verbot dieser Muster kann überlegt werden, welches kontextuell gekoppelt werden könnte. Beispielsweise könnte es Plattformen untersagt werden, zwischen 22 und 6 Uhr Lock-Benachrichtigungen (z.B. "Schau, was du verpasst hast") zu verschicken; für Erwachsene könnte eine Ausnahme vorgesehen werden.

Die Compliance der Plattformen mit diesen Regeln würde im Rahmen der strukturierten Datensammlung bzw. des Feed-TÜV geprüft. Ein Förderprogramm für Verbandsklagen könnte als Katalysator wirken und das Feed-TÜV-Prüfverfahren sollte in den Digital Fairness Act eingebracht werden.

Sichtbare Feed Trade-Offs und bewusstes Mitspracherecht

Die großen Plattformen sortieren Feeds nach Verweildauer und Werbeumsatz und werten dafür das Verhalten jeder Person aus. Engagement-basierte Feeds sind darauf ausgerichtet, Nutzerinnen und Nutzer zu unterhalten, jedoch wurde in Studien gezeigt, dass dies zur Darstellung extremer Inhalte führen kann (z.B. Milli et al., 2025). Mögliche Alternativen beinhalten Feeds, die Meinungspluralismus stärken (siehe Ovadya, 2022; Ovadya & Thorburn, 2023) oder Feeds, die "Public Value" Inhalte betonen. Nutzerinnen und Nutzer sind sich der Folgen der Engagement-orientierung des Standard-Feeds jedoch oftmals nicht bewusst; Daher sollten Trade-offs (z.B. weniger Desinformation, dafür weniger Nachrichten; weniger Profiling, dafür unpassendere Inhalte) zwischen den Feed-Typen explizit gemacht werden, und Nutzerinnen und Nutzer sollten die Wahl zwischen verschiedenen Feed-Typen haben.

Zurzeit sind die Wahlmöglichkeiten zu begrenzt und informieren die Leute zu wenig im Detail über diese Trade-offs. Art. 38 DSA verlangt zum Beispiel von sehr großen Plattformen bereits heute einen Feed ohne Profiling, Art. 27 DSA die Offenlegung der Ranking-Parameter. Bei großen Plattformen sollten also bereits heute chronologische Feeds ausgewählt werden können. Die typische Voreinstellung jedoch sind Feeds, die auf Werbewert basieren und auf Verweildauer und Werbeumsatz optimiert sind. Ein Public-Value-Feed würde dagegen bevorzugt Angebote, die als öffentlich wertvoll anerkannt werden (im Sinne von § 84 Medienstaatsvertrag). Ein alternatives "Bridging Ranking" stuft Beiträge dann hoch, wenn sie

Menschen auf der Plattform positiv bewerten, die ansonsten unterschiedlicher Meinung sind (Ovadya, 2022; Ovadya & Thorburn, 2023).

Weil entsprechende Experimente noch fehlen, sind Bridging- und Public-Value-Feeds wählbar aber keine Standardeinstellung oder Pflicht. Wir schlagen so schnell wie möglich eine grossangelegte Studie zu verschiedenen Ranking-Methoden (Public Value; Bridging; etc.).

Werbewert-Abgabe mit Bonus: Wer sicher gestaltet, zahlt weniger

Plattformen haben grundsätzlich einen Anreiz, die Vorschläge oben zu unterlaufen oder ihnen entgegenzuwirken, da ihre Umsätze maßgeblich davon abhängen, wie lange Nutzerinnen und Nutzer in ihren Feeds (personalisierte) Werbung sehen. An diesem Anreiz setzt eine strukturierte Werbewert-Abgabe an: Wer Lockrufe weiter einsetzt oder den Feed ohne Profiling unattraktiv gestaltet, zahlt den vollen Satz, wer die Vorschläge umsetzt, einen niedrigeren, sodass sich das Unterlaufen nicht mehr lohnt. Sehr große Plattformen zahlen eine Abgabe auf ihre Werbeumsätze in Deutschland (ähnlich zum Modell Österreich). Der Satz könnte zwischen 5 % (Österreich) und 10 % («Plattform-Soli», Weimer) liegen. Wesentlich ist, dass der Steuersatz deutlich sinkt, sobald der Feed-TÜV die positive Prüfung einer Plattform bestätigt, z.B. auf ein Drittel: Wer sicher gestaltet, zahlt weniger. Eine solche Ausgestaltung würde auch die gesellschaftliche Logik bezüglich Plattformen drehen: Nicht mehr Forschung und Gesellschaft müssten nachweisen, dass Plattformen Schaden anrichten, sondern Plattformen würden die Last tragen, zu zeigen, dass sie keinen (oder weniger) Schaden erzeugen.

Die Abgabe kann nur Werbeumsätze im Werbewert-Feed erfassen; das trifft das riskante Geschäftsmodell gezielt, verlangt aber getrennte Meldungen nach Feed. Alternativ erfasst sie wie in Österreich alle Online-Werbeumsätze; das ist erprobt und leicht zu erheben, lenkt aber nur über den Bonus. Die Einnahmen können in Medien- und KI-Bildung fließen sowie in dringend benötigte Forschung zum Thema und in die Feed-TÜV-Stelle; oder sogar in eine offene Alternative zu den kommerziellen Plattformen (Mueller-Bloch & Ciriello, 2026). Optional haften Plattformen zusätzlich für vorhersehbare Schäden aus nicht entschärftem Design.

Bildung zu Empfehlungssystemen: Alle erreichen

Bund und Länder sollten sicherstellen, dass jede Person in einem Bildungskontext eine qualifizierte Einführung in Empfehlungssysteme erhält: 30 bis 45 Minuten mit standardisierten Materialien, zugeschnitten auf Zielgruppen wie Grundschule, Sekundarstufe, berufliche Bildung, Hochschule und Erwachsenenbildung. Die Einführung erklärt, nach welchen Signalen ein Feed auswählt, worauf er optimiert, wie Lockrufe wirken und wie man einen Feed ohne Profiling wählt. Materialien sind frei verfügbar und werden regelmäßig aktualisiert.

Neue Technologien, neue Herausforderungen

Wir sprechen derzeit über soziale Medien, aber die nächste Generation von Plattformen ist bereits vorhanden. Die EU-Kommission hat ChatGPT Search im August 2026 als sehr grosse

Online-Suchmaschine nach dem DSA benannt, weil der Dienst auch das Web durchsucht (EU-Kommission 2026b). ChatGPT und KI-Chatbots werden aber für einiges mehr als bloss Suche verwendet und es stellen sich ganz neue Fragestellungen an die Gesellschaft und Politik. Jedoch kennen wir viele der bereits bekannten Probleme, zum Beispiel die Analyse von Systemrisiken oder Designeinstellungen, die zu mehr Interaktion verlocken, bereits - und haben mit Hebeln I-IV eine Taxonomie an entsprechenden Regulierungsinstrumenten. In diesem Bereich benötigt es jedoch noch dringender wissenschaftlich fundierte Evidenz (v.a. Langzeiteffektmessungen). Was wir bereits wissen: Bei sozialen Medien lag die Sammlung von Belegen über ihre Wirkung zu lange bei den Plattformen selbst, und dies ist immer noch der Fall. Für KI-Chatbots sollte von Anfang an gelten, dass unabhängige Stellen messen können, wie sie wirken.

Quellen

Barnes, C. et al. (2026). Assessing early effects of Australia's Social Media Minimum Age Act on adolescents' social media use: observational study. BMJ 393, e363695.

Bekavac, L. & Mayer, S. (2026). Auditing Meta and TikTok Research API Data Access under Article 40(12) of the Digital Services Act. arXiv:2601.12390 (Preprint).

Bekavac, L., Strecker-Bischoff, J., Garcia, K., Mayer, S. & Tamò-Larrieux, A. (2026). Scrutinizing Systemic Risks in Personalized Recommender Systems Through Sock-Puppet Auditing of VLOPs. ACM Transactions on Recommender Systems 5(1), 1–47.

Boratto, L., De Conca, S., Fabbri, F. & Fabris, A. (2026). From Relevance to Reward: A Pipeline View of Addictive Design in Recommender Systems under the DSA. PMLR 350.

Braghieri, L., Levy, R. & Makarin, A. (2022). Social Media and Mental Health. American Economic Review 112(11), 3660–3693.

Connecticut Attorney General (2026). Attorney General Tong Announces $17.1 Billion Settlement with Meta, Forces Sweeping Child-Safety Reforms on Instagram and Facebook. Pressemitteilung, 26. August 2026.

Cyberspace Administration of China (2024). Leitlinien zum Aufbau eines Minderjährigenmodus im mobilen Internet (移动互联网未成年人模式建设指南), 15. November 2024.

Di Geronimo, L., Braz, L., Fregnan, E., Palomba, F. & Bacchelli, A. (2020). UI Dark Patterns and Where to Find Them: A Study on Mobile Applications and User Perception. CHI '20.

Discord (2025). Update on a Security Incident Involving Third-Party Customer Service.

DSA40 Data Access Collaboratory (2026). DSA40 Tracker Insights. Stand 8. September 2026.

ECNL (2026). Five lessons from three years of risk assessments under the Digital Services Act. EDRi, 18. März 2026.

EU-Kommission (2026a). Commission preliminarily finds TikTok's addictive design in breach of the Digital Services Act. Pressemitteilung IP/26/312.

EU-Kommission (2026b). Commission designates ChatGPT, Reddit, Roblox under Digital Services Act. Pressemitteilung IP/26/1772.

EU-Kommission (2026c). EU KIDS Act: helping children navigate a safer online world. 17. September 2026.

Fitz, N. et al. (2019). Batching smartphone notifications can improve well-being. Computers in Human Behavior 101, 84–94.

Gauthier, G., Hodler, R., Widmer, P. & Zhuravskaya, E. (2026). The political effects of X's feed algorithm. Nature 652, 416–423.

Gerechtshof Amsterdam (2026). Bits of Freedom gegen Meta, Berufungsurteil, ECLI:NL:GHAMS:2026:594.

Guess, A. et al. (2023). How do social media feed algorithms affect attitudes and behavior in an election campaign? Science 381, 398–404.

Guitton, C., Tamò-Larrieux, A. & Mayer, S. (2022). A typology of automatically processable regulation. Law, Innovation and Technology 14(2), 267–304.

Inverarity, C., et al. (2026). Bye-bye Brussels Effect. Hello, Beijing Effect! Open Data Institute, Blog, 29. September 2026.

Kaushal, R., van de Kerkhof, J., Goanta, C., Spanakis, G. & Iamnitchi, A. (2024). Automated Transparency: A Legal and Empirical Analysis of the Digital Services Act Transparency Database. FAccT '24, 1121–1132.

Keller, D. (2021). The Future of Platform Power: Making Middleware Work. Journal of Democracy 32(3), 168–172.

Kushlev, K., Proulx, J. & Dunn, E. W. (2016). "Silence Your Phones": Smartphone Notifications Increase Inattention and Hyperactivity Symptoms. CHI '16, 1011–1020.

Luguri, J. & Strahilevitz, L. J. (2021). Shining a Light on Dark Patterns. Journal of Legal Analysis 13(1), 43–109.

Lukoff, K. et al. (2021). How the Design of YouTube Influences User Sense of Agency. CHI '21.

Milli, S. et al. (2025). Engagement, user satisfaction, and the amplification of divisive content on social media. PNAS Nexus 4(3), pgaf062.

Mueller-Bloch, C. & Ciriello, R. (2026). Governing Social Media as a Public Utility. Communications of the ACM 69(10).

New York State (2026). Governor Hochul and Attorney General James Announce Final SAFE for Kids Act Rules to Protect Children Online.

OLG Bamberg (2025). Verbraucherzentrale Bundesverband gegen CTS Eventim, Urteil vom 5. Februar 2025, 3 UKl 11/24 e.

Orben, A. & Przybylski, A. K. (2019). The association between adolescent well-being and digital technology use. Nature Human Behaviour 3, 173–182.

Ovadya, A. (2022). Bridging-Based Ranking. Belfer Center for Science and International Affairs, Harvard Kennedy School.

Ovadya, A. & Thorburn, L. (2023). Bridging Systems: Open Problems for Countering Destructive Divisiveness across Ranking, Recommenders, and Governance. arXiv:2301.09976 (Preprint).

Piccardi, T. et al. (2025). Reranking partisan animosity in algorithmic social media feeds alters affective polarization. Science 390, eadu5584.

PRO Medienmagazin (2026). Bundesregierung plant schärferen Jugendschutz in sozialen Medien.

Rechtbank Amsterdam (2025). Bits of Freedom gegen Meta, Urteil im Eilverfahren (kort geding) vom 2. Oktober 2025, C/13/774725 / KG ZA 25-687.

Richtlinie (EU) 2024/2853 des Europäischen Parlaments und des Rates vom 23. Oktober 2024 über die Haftung für fehlerhafte Produkte.

Tamò-Larrieux, A., Zihlmann, Z., Garcia, K. & Mayer, S. (2021). The Right to Customization: Conceptualizing the Right to Repair for Informational Privacy. Privacy Technologies and Policy, Springer.

Wagner, M. W. (2023). Independence by permission. Science 381, 388–391.